

ESTRUCTURA DE DATOS PARA LA CLASIFICACIÓN Y OPTIMIZACIÓN APLICADA A LA GANADERÍA DE PRECISIÓN

María Antonia Velásquez
Universidad EAFIT
Colombia
mavelasqur@eafit.edu.co

Diego Alexander Múnera
Universidad EAFIT
Colombia
damunerat@eafit.edu.co

Simón Marín
Universidad Eafit
Colombia
smaring1@eafit.edu.co

Mauricio Toro
Universidad Eafit
Colombia
mtorobe@eafit.edu.co

RESUMEN

Desarrollar un método óptimo mediante el cual pueda llevarse a cabo el control de calidad y análisis del proceso ganadero de manera precisa y automatizada realizando un estudio de la apariencia del ganado que convertido en fragmentos de texto más detallados, es decir, sometido a descompresión permita la clasificación de este con el más mínimo margen de error

Esta alternativa permitirá un estudio más acertado a la hora de evaluar el proceso ganadero en las granjas para conocer el ganado en buen y mal estado lo cual es indispensable tratándose del consumo humano de este y de crear tal alternativa tomando en cuenta el detalle más mínimo puede acertar en el proceso más que el ojo humano para además optimizar tiempo, materia prima y errores

Palabras clave

Algoritmos de compresión, aprendizaje de máquina, aprendizaje profundo, ganadería de precisión, salud animal.

1. INTRODUCCIÓN

La actividad ganadera es una de las más básicas e importantes en el desarrollo de la vida diaria pues de allí provienen productos como leche y carne para el consumo humano.

Debido a esto, es de vital importancia cuidar el estado del ganado durante su desarrollo y proceso de producción que terminará en el mercado.

Y es por esto que, la implementación de tecnologías inteligentes, la inteligencia artificial y el lenguaje de máquina nos brindaría un estudio minucioso del estado del ganado durante todo su proceso de producción permitiendo además que este proceso dure menos tiempo y tenga menos fallas en su análisis.

1.1. Problema

Comprimir las imágenes de ganado para clasificar la salud animal en el contexto de la ganadería de precisión permitiría que el ganado en mal estado pueda quedar fuera de consideración para la producción y distribución del producto final con un mayor índice de

acertación y optimización del tiempo. Con esto a su vez, se evitarían enfermedades en los humanos debido a la carne en mal estado que producirían vacas enfermas que no fueron clasificadas correctamente.

1.2 Solución

En este trabajo, utilizamos una red neuronal convolucional para clasificar la salud animal, en el ganado vacuno, en el contexto de la ganadería de precisión (GdP). Un problema común en la GdP es que la infraestructura de la red es muy limitada, por lo que se requiere la compresión de los datos.

Expliquen, brevemente, su solución al problema (En este semestre, la solución es una implementación de algoritmos de compresión. ¿Qué algoritmos han elegido? ¿Por qué?)

1.3 Estructura del artículo

En lo que sigue, en la Sección 2, presentamos trabajos relacional con el problema. Más adelante, en la Ssección 3, presentamos los conjuntos de datos y los métodos utilizados en esta investigación. En la Sección 4, presentamos el diseño del algoritmo. Después, en la Sección 5, presentamos los resultados. Finalmente, en la Sección 6, discutimos los resultados y proponemos algunas direcciones de trabajo futuras.

2. TRABAJOS RELACIONADOS

En lo que sigue, explicamos cuatro trabajos relacionados. en el dominio de la clasificación de la salud animal y la compresión de datos. en el contexto del PLF.

Explique cuatro (4) artículos relacionados con el problema descrito en la sección 1.1. Puede encontrar los problemas relacionados en las revistas científicas, en lo posible, en inglés. Considere Google Scholar para su búsqueda. *(En este semestre, el trabajo relacionado es la investigación sobre la clasificación de la salud animal y la compresión de datos, en el contexto de la GdP).*

3.1 Escriba un título para el primer problema

Deberían mencionar el problema que resolvieron, el algoritmo que usaron, la métrica que obtuvieron y la cita de ACM.

3.2 Escriba un título para el segundo problema

Deberían mencionar el problema que resolvieron, el algoritmo que usaron, la métrica que obtuvieron y la cita de ACM.

3.3 Escriba un título para el tercer problema

Deberían mencionar el problema que resolvieron, el algoritmo que usaron, la métrica que obtuvieron y la cita de ACM.

3.4 Escriba un título para el cuarto problema

Deberían mencionar el problema que resolvieron, el algoritmo que usaron, la métrica que obtuvieron y la cita de ACM.

3. MATERIALES Y MÉTODOS

En esta sección, explicamos cómo se recogieron y procesaron los datos y, después, diferentes alternativas de algoritmos de compresión de imágenes para mejorar la clasificación de la salud animal.

3.1 Recopilación y procesamiento de datos

Recogimos datos de *Google Images* y *Bing Images* divididos en dos grupos: ganado sano y ganado enfermo. Para el ganado sano, la cadena de búsqueda era "cow". Para el ganado enfermo, la cadena de búsqueda era "cow + sick".

En el siguiente paso, ambos grupos de imágenes fueron transformadas a escala de grises usando Python OpenCV y fueron transformadas en archivos de valores separados por comas (en inglés, CSV). Los conjuntos de datos estaban equilibrados.

El conjunto de datos se dividió en un 70% para entrenamiento y un 30% para pruebas. Los conjuntos de datos están disponibles en <https://github.com/mauriciotoro/ST0245-Eafit/tree/master/proyecto/datasets>.

Por último, utilizando el conjunto de datos de entrenamiento, entrenamos una red neuronal convolucional para la clasificación binaria de imágenes utilizando *Teachable Machine* de Google disponible en <https://teachablemachine.withgoogle.com/train/image>.

3.2 Alternativas de compresión de imágenes con pérdida

A continuación, serán presentados diferentes algoritmos existentes usados para comprimir imágenes con pérdida de algunos parámetros para reducir la memoria utilizada.

3.2.1 Nearest-neighbor interpolation


Este algoritmo está enfocado en reemplazar cada pixel con el que este más cercano en la salida para aumentar la escala

de la imagen. A partir de esto, se introducen irregularidades en las imágenes que fuesen suaves antes de la codificación. La complejidad del algoritmo está enfocada en que el vecino mas cercano no se refiere como tal a este matematicamente sino, un redondeo, haciendo más facil de calcular el tamaño.




3.2.2 Bilinear and bicubic algorithm

Este algoritmo parte de su funcionalidad interpolando los valores de color en cada pixel, introduciendo una transición continua en la salida. Este algoritmo logra reducir los bordes nitidos de la imagen. La complejidad de este algoritmo surge a partir de sus dos formas de ejecutarse, bilineal y bicubicamente; una genera la imagen con bordes pixelados y la otra con bordes lisos pero con un costo computacional alto.



3.2.3 Box sampling

Este algoritmo consiste en tomar el pixel destino como una 'caja' en la imagen original y luego mapear todos los pixeles dentro de la caja. Esto con el fin de que al convertir de nuevo la imagen, todos los pixels contribuyan a la salida. La complejidad de ese algoritmo radicó en eliminar los errores o las debilidades de algoritmos como 'Sinc and Lanczos sampling' con su baja optimización de pixeles.



3.2.4 Vectorization

Este algoritmo extrae las representaciones visuales de la resolución del grafico a comprimir como vectores independientes y luego, esta version se representa como una imagen rasterizada con una resolución optima.




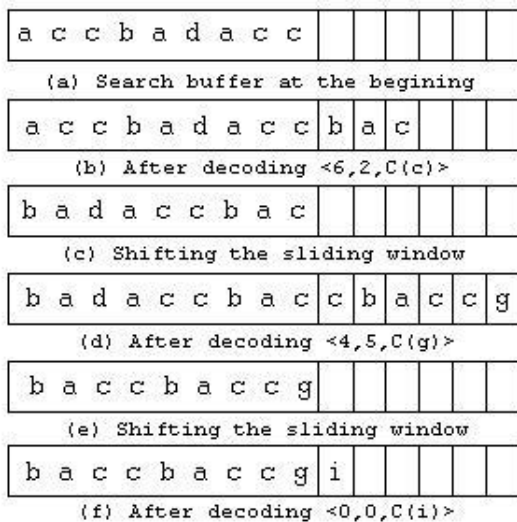
Figure 3.8 A Simple Vectorization Algorithm

3.3 Alternativas de compresión de imágenes sin pérdida

En lo que sigue, presentamos diferentes algoritmos usados para comprimir imágenes sin pérdida.


3.3.1 LZ77_and_LZ78

Este algoritmo logra la compresion de imagenes reemplazando las ocurrencias repetidas de datos con referencias en memoria a una sola copia de esos datos existentes anteriormente en el flujo de datos sin comprimir. La complejidad de este algoritmo radica en que para encontrar las coincidencias se codifican dos números que, están llamados longitude-distancia y estos denominan el desplazamiento en el buffer del flujo de datos sin comprimir.



3.3.2 Huffman Compression Algorithm

Este algoritmo funciona creando un arbol binario de nodos en los que se puede almacenar un vector regular, cuyo tamaño depende del numero de símbolos n . Cada nodo puede ser un nodo hoja o un nodo interno. En cada uno de estos aparece inicialmente su simbolo y su frecuencia de aparición. Así que, las letras se ordenan aumentando la frecuencia y las menos frecuentes en cada paso se combinan y reinsertan construyendo un arbol parcial.



3.3.3 Burrows Wheeler transform


Este algoritmo trabaja con el concepto de compresion por clasificacion de bloques, éste reorganiza una cadena de caracteres en series de estos mismos similares. Este tipo de algoritmo es util y en esto a su vez radica su complejidad; en la codificación de cadenas con longitudes repetidas y su reversibilidad.

Index	T	F	L
0	3	A	N (rows 4)
1	4	A	N (rows 2)
2	5	A	B (rows 0)
* 3	2	B	A (rows 5)
4	0	N	A (rows 3)
5	1	N	A (rows 1)

3.3.4 GS-2D-LZ

Este algoritmo de compresión esta enfocado en codificar por orden de procesamiento un bloque por pixel en cada paso. Luego un valor aproximado se busca en la imagen previa a la compresión y el bloque es señalado como un puntero de la localización de su igual, sus dimensiones y su

información residuo. Mediante este método se asegura que la compression no tendra perdidas.



4. DISEÑO E IMPLEMENTACIÓN DE LOS ALGORITMOS

En lo que sigue, explicamos las estructuras de datos y los algoritmos utilizados en este trabajo. Las implementaciones de las estructuras de datos y los algoritmos están disponibles en Github¹.

4.1 Estructuras de datos

Explique la estructura de datos utilizada para hacer la compresión de las imágenes y haga una figura que la explique. No utilice figuras de Internet. (En este semestre, ejemplo de las estructuras de datos son los árboles y las tablas hash)




Figura 1: Árbol de Huffman generado a partir de las frecuencias exactas del texto "this". (Por favor, no dude en cambiar esta figura si utilizan una estructura de datos diferente).

4.2 Algoritmos

En este trabajo, proponemos un algoritmo de compresión que es una combinación de un algoritmo de compresión de imágenes con pérdidas y un algoritmo de compresión de

imágenes sin pérdidas. También explicamos cómo funciona la descompresión para el algoritmo propuesto.

Expliquen el diseño de los algoritmos para resolver el problema y hagan una figura. No uses figuras de Internet, haz las tuyas propias. (En este semestre, un algoritmo debe ser un algoritmo de compresión de imágenes con pérdidas, como el escalado de imágenes, el tallado de costuras o la compresión con ondeletas, y el segundo algoritmo debe ser un algoritmo de compresión de imágenes sin pérdidas, como la codificación Huffman, LZS o LZ77).

4.2.1 Algoritmo de compresión de imágenes con pérdida

Explique, brevemente, cómo se aplicó un algoritmo de compresión de imágenes con pérdidas, como, por ejemplo, el tallado de costuras o el escalado de imágenes. Explique también la descompresión.




Figura 2: Escalado de la imagen mediante interpolación bilineal. (Por favor, siéntase libre de cambiar esta figura si utiliza una estructura de datos diferente).

4.2.2 Algoritmo de compresión de imágenes sin pérdida

Explique brevemente cómo aplicó un algoritmo de compresión de imágenes sin pérdidas como la codificación Huffman, LZS o LZ77. Explique también la descompresión.

4.3 Análisis de la complejidad de los algoritmos

Explique, con sus propias palabras, el análisis del peor caso usando la notación O. ¿Cómo calculó tales complejidades. Por favor, explique brevemente.

Algoritmo	La complejidad del tiempo
Compresión	$O(N^2 \cdot M^2)$
Descompresión	$O(N^3 \cdot M \cdot 2^N)$

Tabla 2: Complejidad temporal de los algoritmos de compresión y descompresión de imágenes. (Por favor, explique qué significan N y M en este problema).

¹<http://www.github.com/ ???????? /proyecto/>

Algoritmo	Complejidad de la memoria
Compresión	$O(N*M*2N)$
Descompresión	$O(2M*2N)$

Tabla 3: Complejidad de memoria de los algoritmos de compresión y descompresión de imágenes. (Por favor, explique qué significan N y M en este problema).

4.4 Criterios de diseño del algoritmo

Explica por qué el algoritmo fue diseñado de esa manera. Use un criterio objetivo. Los criterios objetivos se basan en la eficiencia, que se mide en términos de tiempo y consumo de memoria. Ejemplos de criterios no objetivos son: "Estaba enfermo", "fue la primera estructura de datos que encontré en Internet", "lo hice el último día antes del plazo", etc. Recuerde: Este es el 40% de la calificación del proyecto.

5. RESULTADOS

5.1 Evaluación del modelo

En esta sección, presentamos algunas métricas para evaluar el modelo. La exactitud es la relación entre el número de predicciones correctas y el número total de muestras de entrada. La precisión es la proporción de estudiantes exitosos identificados correctamente por el modelo a estudiantes exitosos identificados por el modelo. Por último, sensibilidad es la proporción de estudiantes exitosos identificados correctamente por el modelo a estudiantes exitosos en el conjunto de datos.

5.1.1 Evaluación del conjunto de datos de entrenamiento

A continuación presentamos las métricas de evaluación del conjunto de datos de entrenamiento en la Tabla 3.

	Conjunto de datos de entrenamiento
Precisión	0.02
Precisión	0.03
Recordar	0.01

Tabla 3. Evaluación del modelo de clasificación de imágenes con el conjunto de datos de entrenamiento.

5.1.2 Evaluación del conjuntos de datos de prueba

A continuación presentamos las métricas de evaluación del conjunto de datos de prueba, en la Tabla 4, sin compresión y, en la Tabla 5, con compresión.

	Conjunto de datos de prueba
Exactitud	0.01
Precisión	0.012
Sensibilidad	0.013

Tabla 4. Evaluación del modelo de clasificación de imágenes, con el conjunto de datos de prueba, sin compresión.

	Conjunto de datos de prueba
Exactitud	0.001
Precisión	0.0012
Sensibilidad	0.0013

Tabla 5. Evaluación del modelo de clasificación de imágenes, con el conjunto de datos de prueba, con compresión.

5.2 Tiempos de ejecución

En lo que sigue explicamos la relación entre el tiempo promedio de ejecución y el tamaño promedio de las imágenes del conjunto de datos completo, en la Tabla 6.

Calcular el tiempo de ejecución de cada imagen en Github. Informar del tiempo medio de ejecución vs. el tamaño medio del archivo.

	Tiempo promedio de ejecución (s)	Tamaño promedio del archivo (MB)
Compresión	100.2 s	12.4 MB
Descompresión	800.1 s	12.4 MB

Tabla 6: Tiempo de ejecución de los algoritmos (Por favor, escriba el nombre de los algoritmos, por ejemplo, tallado de costuras y LZ77) para diferentes imágenes en el conjunto de datos.

5.3 Consumo de memoria

Presentamos el consumo de memoria de los algoritmos de compresión y descompresión en la Tabla 7.

	Consumo promedio de memoria (MB)	Tamaño promedio del archivo (MB)

Compresión	634 MB	3.12 MB
Descompresión	9 MB	878.12 MB

Tabla 7: Consumo promedio de memoria de todas las imágenes del conjunto de datos, tanto para la compresión como para la descompresión.

Para medir el consumo de memoria, deberían usar un generador de perfiles. Uno muy bueno para Java es VisualVM, desarrollado por Oracle, <http://docs.oracle.com/javase/7/docs/technotes/guides/visualvm/profiler.html>. Para Python, usa el *C profiler*.

5.3 Tasa de compresión

Presentamos los resultados de la tasa de compresión del algoritmo en la Tabla 8.

	<i>Ganado sano</i>	<i>Ganado enfermo</i>
Tasa de compresión promedio	1:23	1:34

Tabla 8: Promedio redondeado de la tasa de compresión de todas las imágenes de ganado sano y ganado enfermo.

6. DISCUSIÓN DE LOS RESULTADOS

Explique los resultados obtenidos. ¿Son la exactitud, la precisión y la sensibilidad apropiadas para este problema? ¿El modelo está sobreajustado? ¿Es apropiado el consumo de memoria y el consumo de tiempo? ¿Es la relación de compresión apropiada? ¿Cambia la compresión significativamente la exactitud con el conjunto de datos de la prueba? (*En este semestre, según los resultados, ¿puede la compresión mejorar la clasificación de la salud animal en el contexto del PLF?*)

6.1 Trabajos futuros

Responda ¿qué le gustaría mejorar en el futuro? ¿Cómo le gustaría mejorar su algoritmo y su implementación? ¿Qué tal usar la transformación de coseno discreto o la compresión con ondeletas a futuro?

RECONOCIMIENTOS

Identifique el tipo de reconocimiento que quiere escribir: para una persona o para una institución. Considere las siguientes pautas: 1. El nombre del profesor no se menciona porque es un autor. 2. No debe mencionar sitios web de autores de artículos que no ha contactado. 3. Debe mencionar estudiantes, profesores de otros cursos que le hayan ayudado.

Como ejemplo: Esta investigación fue apoyada/parcialmente apoyada por [Nombre de la Fundación, Donante, Beca].

Agradecemos la asistencia con [técnica particular, metodología] a [Nombre Apellido, cargo, nombre de la institución] por los comentarios que mejoraron enormemente el manuscrito o la codificación del algoritmo.

REFERENCIAS

La referencia se obtiene usando el formato de referencia ACM. Lea las directrices de ACM en <http://bit.ly/2pZnE5g>

A modo de ejemplo, consideremos estas dos referencias:

1. Adobe Acrobat Reader 7, Asegúrate de que el texto de las secciones de referencia es *Ragged Right*, Not Justified. <http://www.adobe.com/products/acrobat/>.
2. Fischer, G. y Nakakoji, K. Amplificando la creatividad de los diseñadores con entornos de diseño orientados al dominio. en Dartnall, T. ed. Artificial Intelligence and Creativity: An Interdisciplinary Approach, Kluwer Academic Publishers, Dordrecht, 1994, 343-364.

Por favor, quite las referencias de arriba, son sólo un ejemplo.